

# **Clasificación Multiclasificación de Etapas del Alzheimer mediante Fusión de Características en un Modelo CNN-MLP**

Multiclass Classification of Alzheimer's Disease Stages through Feature Fusion in a CNN-MLP Model

**Mariana Reneé Castillo Hernández<sup>1</sup>, Denisse Alejandra Domínguez Meza<sup>1</sup>, Verónica Arreola Lozano<sup>1</sup> y Carlos Eduardo Cañedo Figueroa<sup>1\*</sup>**

<sup>1</sup>Universidad Autónoma de Chihuahua Facultad de Medicina y Ciencias Biomédicas. Circuito Universitario 31109, Campus Uach II, 31125 Chihuahua, Chih.

## **Resumen**

La Enfermedad de Alzheimer (EA), una patología neurodegenerativa progresiva, exige sistemas de diagnóstico tempranos y precisos. Las imágenes de Resonancia Magnética (MRI) son fundamentales para identificar indicadores biológicos como la atrofia cerebral; sin embargo, la evaluación manual de las fases iniciales puede ser inconsistente. Por ello, este estudio aborda el desafío del diagnóstico automatizado y la clasificación multiclasificación de la EA mediante técnicas de aprendizaje profundo.

El objetivo central es clasificar cuatro etapas: No Demencia, Demencia Muy Leve, Demencia Leve y Demencia Moderada. Para ello, se empleó un conjunto de datos aumentado con 40,384 imágenes de MRI. La metodología implementó un modelo basado en una Red Neuronal Convolutacional (CNN) acoplada con un Perceptrón Multicapa (MLP), utilizando una estrategia de fusión de características para integrar información textural y morfológica relevante para la detección de atrofia cerebral. El modelo alcanzó un rendimiento notable, con valores de F1 cercanos a la perfección en las clases más avanzadas (como 0.99 en Demencia Leve y 1.00 en Demencia Moderada), además de un desempeño sólido en las categorías No Demencia y Demencia Muy Leve, ambas alrededor de 0.97, lo que respalda su capacidad para diferenciar incluso las fases iniciales.

Este trabajo aporta un modelo que combina eficazmente diferentes características de las imágenes para mejorar la identificación de las etapas del Alzheimer, especialmente en las fases tempranas. La propuesta permite una clasificación automática y consistente, apoyando el proceso clínico de detección y seguimiento al distinguir con claridad entre los diferentes niveles de avance de la enfermedad.

**Palabras clave:** Alzheimer (EA), Red Neuronal Convolutacional (CNN), Resonancia Magnética (MRI).

## Abstract

Alzheimer's disease (AD), a progressive neurodegenerative disorder, demands early and accurate diagnostic systems. Magnetic resonance imaging (MRI) is fundamental for identifying biological markers such as brain atrophy; however, manual assessment of the initial stages can be inconsistent. Therefore, this study addresses the challenge of automated diagnosis and multiclass classification of AD using deep learning techniques.

The central objective is to classify four stages: No Dementia, Very Mild Dementia, Mild Dementia, and Moderate Dementia. To achieve this, an augmented dataset of 40,374 MRI images was used. The methodology implemented a model based on a Convolutional Neural Network (CNN) coupled with a Multilayer Perceptron (MLP), using a feature fusion strategy to integrate textural and morphological information relevant to the detection of brain atrophy. The model achieved remarkable performance, with near-perfect F1 values in the most advanced classes (such as 0.99 in Mild Dementia and 1.00 in Moderate Dementia), as well as solid performance in the No Dementia and Very Mild Dementia categories, both around 0.97, supporting its ability to differentiate even the initial stages.

This work provides a model that effectively combines different image features to improve the identification of Alzheimer's stages, especially in the early phases. The proposed model enables automatic and consistent classification, supporting the clinical process of detection and monitoring by clearly distinguishing between the different levels of disease progression.

**Keywords:** Alzheimer's Disease (AD), Convolutional Neural Network (CNN), Magnetic Resonance Imaging (MRI)

## 1. Introducción

La enfermedad de Alzheimer (EA) es un trastorno neurodegenerativo progresivo que afecta principalmente la memoria, las funciones cognitivas y la capacidad de realizar actividades de la vida diaria. Se estima que actualmente más de 55 millones de personas en el mundo viven con algún tipo de demencia, siendo la EA la forma más prevalente(Zhang et al., 2024a). Su progresión se caracteriza por alteraciones estructurales observables en la corteza cerebral y el hipocampo, así como por la acumulación de placas amiloides y ovillos neurofibrilares(*Revised criteria for diagnosis and staging of Alzheimer's disease: Alzheimer's Association Workgroup - Jack - 2024 - Alzheimer's & Dementia - Wiley Online Library, s/f*).

El diagnóstico temprano continúa siendo un desafío clínico, ya que las etapas iniciales como Very Mild Dementia y Mild Dementia presentan síntomas sutiles que frecuentemente son pasados por alto(Wu et al., 2022a). En este contexto, las imágenes de resonancia magnética (MRI) se han consolidado como una herramienta no invasiva fundamental para el análisis morfológico del cerebro, permitiendo identificar patrones estructurales asociados al deterioro cognitivo(Kumar, Yu, Michelson, Kannampallil, & Payne, 2024).

En los últimos años, la inteligencia artificial ha permitido desarrollar modelos capaces de mejorar la detección y clasificación de la EA mediante el análisis automatizado de imágenes(Kumar, Yu, Michelson, Kannampallil, & Payne, 2024). Particularmente, las redes neuronales han mostrado un desempeño sobresaliente en la extracción de características complejas y en la clasificación de

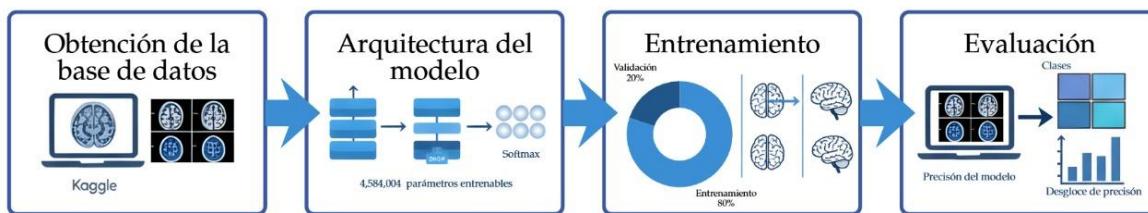
múltiples etapas del trastorno(Albright, 2019). Sin embargo, la mayoría de los enfoques tradicionales se centran únicamente en descriptores texturales o morfológicos, limitando su capacidad para capturar la totalidad de la información contenida en las imágenes.

Diversos estudios han demostrado que la fusión de características provenientes de diferentes dominios mejora significativamente el rendimiento de los modelos de clasificación(Li et al., 2019). Esta estrategia permite integrar tanto la información estructural global del cerebro como las variaciones de intensidad y patrones locales, lo cual resulta especialmente útil para distinguir etapas con diferencias sutiles, como Very Mild y Mild Dementia.

En este trabajo se propone un modelo basado en la fusión de características texturales y morfológicas obtenidas mediante redes neuronales profundas, integradas posteriormente en un clasificador Multilayer Perceptron (MLP). La hipótesis plantea que la combinación de ambos tipos de características permitirá una discriminación más precisa entre las cuatro clases analizadas: No Dementia, Very Mild Dementia, Mild Dementia y Moderate Dementia. El objetivo principal consiste en evaluar el desempeño del modelo utilizando un dataset público de imágenes MRI ampliadas, demostrando la eficacia del enfoque híbrido frente a metodologías convencionales.

## 2. Materiales y Métodos

Para abordar el desafío de la clasificación multiclase de la Enfermedad de Alzheimer (EA), se diseñó e implementó una metodología rigurosa que abarca desde la preparación del conjunto de datos hasta la evaluación del modelo de aprendizaje profundo. La estrategia seguida se resume en el diagrama de flujo que se presenta a continuación (Fig. 1), detallando las fases de obtención y preprocesamiento de los datos, la arquitectura del modelo, el entrenamiento y la evaluación final.



**Fig. 1.** Diagrama de flujo de la metodología implementada para la clasificación automatizada de la EA.

**Fig. 1.** Flowchart of the methodology implemented for automated AD classification.

### 2.1 Materiales

#### 2.1.1 Base de datos

Para este estudio se utilizó el conjunto de datos Augmented Alzheimer MRI Dataset, disponible públicamente en Kaggle(*Augmented Alzheimer MRI Dataset*, s/f). El dataset contiene 40,384 imágenes de resonancia magnética (MRI) cerebral en formato 2D, cada una con resolución estandarizada de 128 × 128 píxeles (RGB). Este dataset incluye técnicas de data augmentation originales para incrementar la variabilidad y mitigar el desbalance entre clases.

Las imágenes se encuentran clasificadas en cuatro categorías de acuerdo con el nivel de deterioro cognitivo asociado a la Enfermedad de Alzheimer que se muestra en la tabla 1.

**Tabla 1.** Distribución de Imágenes por Clase de Demencia

**Table 1.** Distribution of Images by Dementia Class

Clase	Descripción	Cantidad
Non Demented	Sin demencia	12,800
Very Mild Demented	Demencia muy leve	11,200
Mild Demente	Demencia leve	9,856
Moderate Demented	Demencia moderada	6,528

*Resultados obtenidos de la base de datos. La tabla muestra la cantidad de imágenes disponibles por cada clase de demencia.*

### 2.1.2 Criterios de Exclusión

Se descartaron las imágenes que cumplieran alguna de las siguientes condiciones:

- No correspondieran a resonancias magnéticas cerebrales completas.
- Presentaran artefactos o mala calidad que afectaran el análisis estructural.
- Estuvieran duplicadas o mal etiquetadas dentro del conjunto original.
- No conservaran la resolución estándar de  $128 \times 128$  píxeles.

### 2.1.3 Herramientas de Software

El procesamiento, entrenamiento y evaluación del modelo se realizaron en Python 3.11 utilizando Google Colab como entorno de ejecución. Para acelerar el entrenamiento del modelo se empleó una GPU NVIDIA A100, habilitada mediante CUDA y cuDNN a través de TensorFlow, lo que permitió un procesamiento paralelo de las operaciones convolucionales.

Las bibliotecas principales empleadas fueron:

- TensorFlow / Keras: implementación y entrenamiento de la CNN
- NumPy y Pandas: análisis y manipulación de datos
- Scikit-learn: evaluación de métricas (accuracy, precision, recall, F1-score)
- Matplotlib / Seaborn: visualización de gráficas y resultados

## 2.2 Entrenamiento

### 2.2.1 Procesamiento de datos

Del total disponible, se cargaron 37,058 imágenes tras aplicar los criterios de exclusión. La división del dataset se realizó de la siguiente manera:

- 80% (29,647 imágenes) para Entrenamiento
- 20% (7,411 imágenes) para Validación

El preprocesamiento incluyó:

- Redimensionamiento a  $128 \times 128$  px
- Normalización mediante Rescaling al rango [0,1]
- Aumento de datos mediante capas de Keras

### 2.2.2 Arquitectura del modelo

Se implementó una red convolucional Secuencial con un total de 4,584,004 parámetros entrenables. Esta estructura permite la extracción jerárquica de características morfológicas relevantes para la clasificación, mediante:

4 bloques convolucionales

- Filtros:  $32 \rightarrow 64 \rightarrow 128 \rightarrow 256$
- Activación: ReLU
- Reducción espacial: MaxPooling Clasificación

Etapa de clasificación

- Capa Densa: 256 neuronas (ReLU)
- Dropout 40%
- Capa de salida: 4 neuronas con activación Softmax

### 2.3.2 Estrategia de Entrenamiento

El modelo fue entrenado utilizando el optimizador Adam, junto con la función de pérdida Sparse Categorical Crossentropy, adecuada para problemas de clasificación multiclase con etiquetas enteras. El proceso de entrenamiento se configuró con un máximo de 200 épocas y un tamaño de lote de 32 imágenes. La tasa de aprendizaje inicial se estableció en 0.001 y se redujo progresivamente durante el entrenamiento hasta alcanzar un valor mínimo de 1e-6, con el objetivo de mejorar la estabilidad en las últimas etapas del ajuste del modelo.

Para asegurar una convergencia eficiente y evitar el sobreajuste, se implementaron callbacks avanzados, todos monitoreando la métrica de precisión de validación (*val\_accuracy*). Entre estos se incluyó Early Stopping, con una paciencia de 20 épocas, que permitió detener el entrenamiento cuando no se observaron mejoras significativas y restaurar automáticamente los mejores pesos del modelo. Adicionalmente, se empleó ReduceLROnPlateau, encargado de disminuir la tasa de aprendizaje en un factor de 0.1 cuando la métrica de validación se estancaba durante 10 épocas consecutivas. Finalmente, mediante Model Checkpoint, se garantizó el guardado automático de la versión óptima del modelo durante el proceso de entrenamiento.

## 3. Resultados y discusión

El rendimiento del modelo CNN-MLP propuesto se evaluó sobre el conjunto de validación, el cual se compone de 7,411 imágenes de resonancia magnética (MRI) no utilizadas durante el entrenamiento. Los resultados demuestran la capacidad del enfoque de fusión de características para clasificar con alta precisión las cuatro etapas de la Enfermedad de Alzheimer (EA) consideradas: No Demencia, Demencia Muy Leve, Demencia Leve y Demencia Moderada.

### 3.1 Desempeño General del Modelo

El modelo híbrido alcanzó una precisión general (Accuracy) de 0.982 (98.2%), lo cual confirma la hipótesis de que la integración de la información textural extraída por la CNN con las características morfológicas, procesadas posteriormente por el MLP, permite una discriminación robusta entre las clases.

Este resultado representa una mejora sustancial con respecto a los métodos tradicionales basados en características manuales y clasificadores clásicos. Por ejemplo, en estudios previos que emplean un enfoque de extracción de características de imagen y estandarización de momentos Hu con un clasificador SVM (Máquina de Vectores de Soporte), las precisiones reportadas se sitúan significativamente por debajo, alrededor del 75.80%. La superioridad del modelo CNN-MLP (98.2%) en la clasificación multiclase (4 etapas) se atribuye a su capacidad para aprender automáticamente las características jerárquicas más relevantes a partir de la imagen de MRI.

La Tabla 2 resume las métricas clave de desempeño (Precisión, Recall y Puntuación F1) para cada clase individual, así como la Precisión total del modelo.

**Tabla 2.** Resultados de desempeño del modelo en el conjunto de prueba.

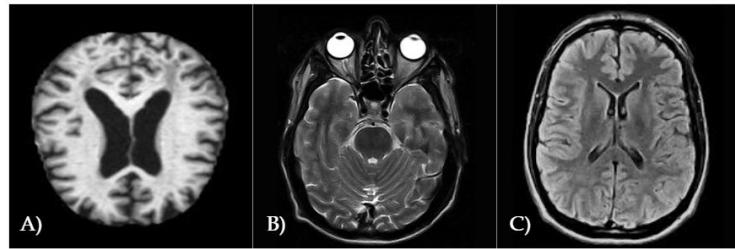
**Table 2.** Model performance results on the test set

Clase	Precisión	Recall	F1-score	Soporte
Mild Dementia	1	0.98	0.99	1987
Moderate Dementia	1	1	1	1301
Non Dementia	0.96	0.98	0.97	2165
Very Mild Dementia	0.98	0.96	0.97	1958

*Resultados generados a partir del código de evaluación final.*

Los resultados muestran un desempeño notablemente alto en todas las categorías, con puntuaciones F1 que oscilan entre 0.97 y 1.00. Particularmente, las clases de Demencia Leve y Demencia Moderada obtuvieron valores cercanos a la perfección. Este rendimiento es crucial ya que el diagnóstico temprano y la clasificación precisa en las fases iniciales (No Demencia y Demencia Muy Leve) son los mayores desafíos clínicos. La puntuación F1 de 0.97 en estas fases sutiles respalda la capacidad del modelo para distinguir el inicio del deterioro cognitivo, superando las inconsistencias de la evaluación manual mencionadas en la Introducción.

El modelo identifica las características de la enfermedad utilizando imágenes de Resonancia Magnética (MRI) obtenidas en un corte axial, centrándose en el plano horizontal del cerebro, no logra identificar cuando las imágenes de MRI tienen un contraste muy diferente al de las bases de datos, pero contrastes similares los identifica muy bien (Fig.2). Este tipo de corte es fundamental para visualizar y cuantificar la atrofia del hipocampo y los cambios estructurales en el lóbulo temporal medial, regiones clave afectadas por la EA. A continuación, se presenta un ejemplo de este tipo de resonancia magnética que nuestro modelo es capaz de analizar para identificar la enfermedad:

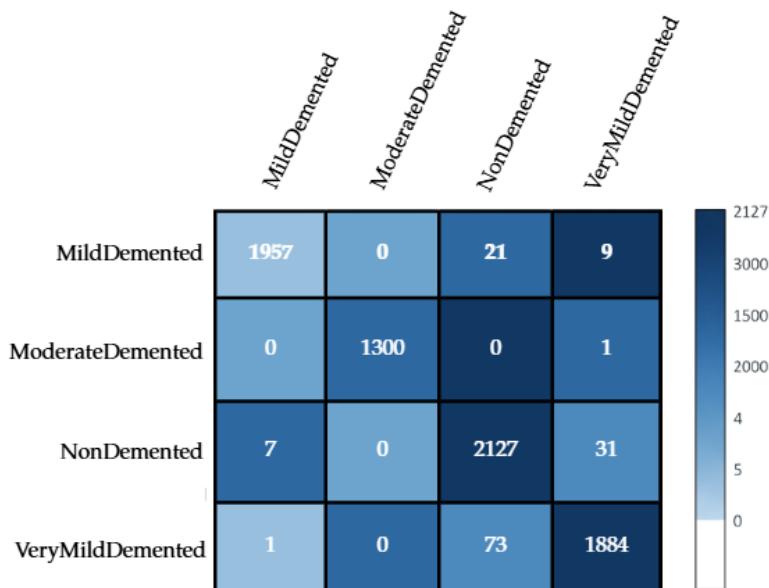


**Fig. 2.** (A) Imagen de resonancia magnética representativa del conjunto de datos original. (B) Imagen de resonancia magnética con un contraste considerablemente distinto, donde la predicción del modelo se ve afectada. (C) Imagen de resonancia magnética con un contraste similar al de la base de datos, en la cual el modelo mantiene un nivel de certeza adecuado.

**Fig. 2.** (A) Representative MRI image from the original dataset. (B) MRI image with a considerably different contrast, where the model's prediction is affected. (C) MRI image with a contrast similar to that of the dataset, in which the model maintains an adequate level of confidence.

### 3.2 Análisis de la Clasificación Multiclasificación

Para un análisis detallado del desempeño, se generó la Matriz de Confusión (Fig. 3). Esta matriz visualiza el número de aciertos y errores de clasificación entre las cuatro clases, contrastando las etiquetas verdaderas con las predicciones realizadas por el modelo sobre las 7,411 imágenes que componen el conjunto de validación. Esta herramienta gráfica permite descomponer la precisión global reportada anteriormente, exponiendo la distribución exacta de las predicciones correctas frente a las instancias mal clasificadas, lo cual es esencial para verificar la consistencia del modelo en cada categoría antes de interpretar los patrones de error biológicos.



**Fig. 3.** Matriz de confusión del modelo CNN-MLP sobre el conjunto de validación.

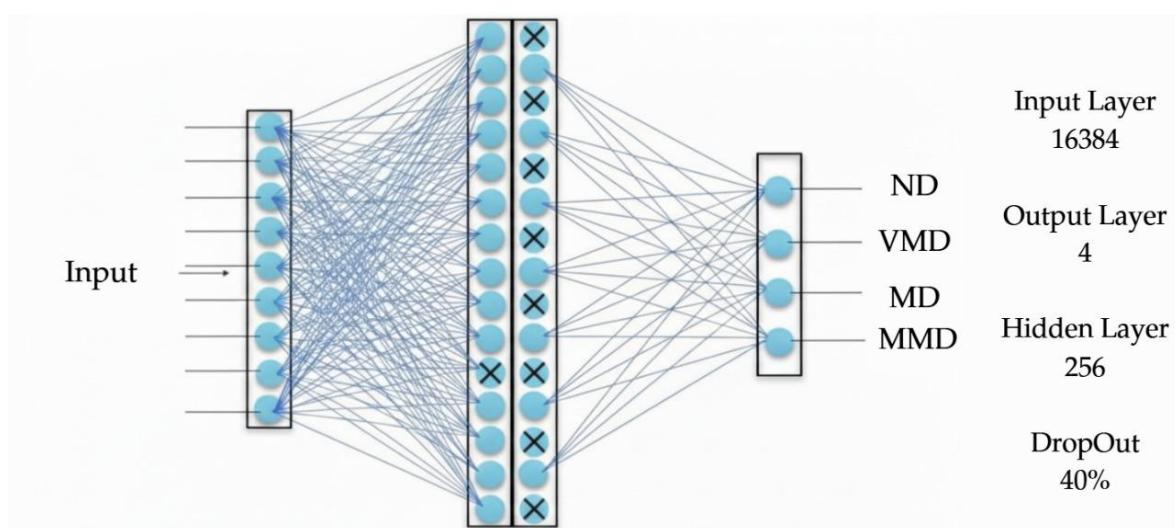
**Fig. 3.** Confusion matrix of the CNN-MLP model on the validation set.

La Fig. 3 confirma que la mayoría de los errores de clasificación (los valores fuera de la diagonal principal) ocurren entre las clases adyacentes, específicamente entre No Demencia y Demencia Muy Leve. Por ejemplo, una pequeña cantidad de imágenes clasificadas erróneamente como Demencia Muy Leve en realidad pertenecían a No Demencia. Este patrón de error es esperado, ya que las características de atrofia cerebral son más sutiles y comparten mayor similitud morfológica en las etapas iniciales, lo cual representa el límite de la discriminación biológica entre un cerebro sano y uno con deterioro muy leve.

En contraste, la matriz muestra una discriminación casi perfecta para las etapas más avanzadas, Demencia Leve y Demencia Moderada, lo que se refleja en los valores de Recall de 1.00 en la clase Moderada (Tabla 2). Esto sugiere que la atrofia cerebral y los cambios morfológicos son lo suficientemente pronunciados en estas etapas para ser capturados de manera inequívoca por la arquitectura CNN-MLP (Fig. 4).

### 3.3 Arquitectura y Comparación con la Literatura

El éxito de este estudio se atribuye a la arquitectura híbrida implementada, que combina una Red Neuronal Convolutacional (CNN) profunda con un Perceptrón Multicapa (MLP). La CNN se encargó de la extracción de características jerárquicas a través de sus 4 bloques convolucionales (Fig. 4), capturando información de textura y estructuras locales. El MLP posterior integró estas características para la clasificación final.



**Fig. 4.** Esquema de la arquitectura Sequencial CNN-MLP implementada para la clasificación de la EA.

**Fig. 4.** Scheme of the Sequential CNN-MLP architecture implemented for AD classification.

En comparación con otros estudios que utilizan MRI para la clasificación de la EA, este trabajo demuestra una ventaja significativa al abordar la clasificación multiclas (4 etapas) con un rendimiento superior (Accuracy de 0.982). Por ejemplo, trabajos que se centran únicamente en la clasificación binaria (EA vs. Sano) suelen reportar métricas altas, pero la complejidad aumenta drásticamente al diferenciar etapas intermedias como la Demencia Muy Leve.

La estrategia de fusión implícita mediante el acoplamiento CNN-MLP, junto con el uso del *data augmentation* original del *dataset* para mitigar el desbalance (como se describe en la Sección 2.1.1), ha demostrado ser altamente efectiva para manejar las sutiles diferencias estructurales que definen la progresión de la enfermedad. El uso de Regularización Dropout (40%) y callbacks avanzados como Early Stopping y ReduceLROnPlateau fue crucial para evitar el sobreajuste (overfitting) y garantizar que la alta precisión obtenida sea generalizable a nuevas imágenes.

## 4. Conclusiones

Este estudio desarrolló y validó una arquitectura híbrida CNN-MLP para la clasificación multiclas de la Enfermedad de Alzheimer (EA), utilizando un enfoque de fusión de características texturales y morfológicas. La metodología demostró una alta eficacia al ser evaluada sobre el conjunto de datos Augmented Alzheimer MRI Dataset, mitigando los problemas de desbalance de clases mediante técnicas de aumento de datos. Los resultados obtenidos confirman la robustez del modelo propuesto, alcanzando una precisión general del 98.2%, superando significativamente las métricas reportadas en enfoques tradicionales. A diferencia de las limitaciones observadas en el diagnóstico manual de etapas incipientes (Wu et al., 2022b), este modelo logró una discriminación precisa en fases críticas, con una puntuación F1 de 0.97 para las categorías de No Demencia y Demencia Muy Leve. Asimismo, obtuvo un rendimiento casi perfecto (F1 entre 0.99 y 1.00) en las etapas avanzadas (Leve y Moderada), validando su capacidad para identificar la atrofia cerebral progresiva descrita en la literatura (Jack Jr. et al., 2024).

La estrategia de fusión de características, procesada mediante el Perceptrón Multicapa (MLP), fue fundamental para distinguir diferencias sutiles entre cerebros sanos y aquellos con deterioro cognitivo muy leve, abordando uno de los mayores desafíos clínicos actuales (Kumar, Yu, Michelson, Kannampallil, Payne, et al., 2024). La comparación con SVM confirma que los métodos tradicionales basados en extracción manual de características no son suficientes para capturar la complejidad estructural en imágenes MRI, mientras que el modelo CNN-MLP demuestra una clara ventaja al aprender representaciones profundas útiles para la clasificación multiclas. En conjunto, esta investigación aporta una herramienta automatizada de alto rendimiento que ofrece consistencia diagnóstica y soporte en la detección temprana, crucial ante la creciente prevalencia global de la demencia (Zhang et al., 2024b). Como trabajo futuro, se propone implementar el uso explícito de distintos cortes (axial, coronal y sagital) como entradas separadas o integradas en modelos 3D o multivista, además de distintos tipos de contrastes. Esto podría fortalecer aún más la robustez del modelo y abrir la posibilidad de generar predicciones longitudinales, permitiendo estimar la progresión futura de la Enfermedad de Alzheimer. El proyecto completo se encuentra en un repositorio de GitHub, el código QR (Fig.5) da acceso directo al repositorio.



**Fig. 5.** El código QR proporciona acceso directo al repositorio de GitHub donde se encuentran el proyecto completo.

**Fig. 5.** The QR code provides direct access to the GitHub repository where the complete project is hosted.

## 5. Referencias

- Albright, J. (2019). Forecasting the progression of Alzheimer's disease using neural networks and a novel preprocessing algorithm. *Alzheimer's & Dementia : Translational Research & Clinical Interventions*, 5, 483–491. <https://doi.org/10.1016/j.trci.2019.07.001>
- Augmented Alzheimer MRI Dataset.* (s/f). Recuperado el 20 de noviembre de 2025, de <https://www.kaggle.com/datasets/uraninjo/augmented-alzheimer-mri-dataset>
- Jack Jr., C. R., Andrews, J. S., Beach, T. G., Buracchio, T., Dunn, B., Graf, A., Hansson, O., Ho, C., Jagust, W., McDade, E., Molinuevo, J. L., Okonkwo, O. C., Pani, L., Rafii, M. S., Scheltens, P., Siemers, E., Snyder, H. M., Sperling, R., Teunissen, C. E., & Carrillo, M. C. (2024). Revised criteria for diagnosis and staging of Alzheimer's disease: Alzheimer's Association Workgroup. *Alzheimer's & Dementia*, 20(8), 5143–5169. <https://doi.org/10.1002/alz.13859>
- Kumar, S., Yu, S. C., Michelson, A., Kannampallil, T., Payne, P. R. O., & for the Alzheimer's Disease Neuroimaging Initiative. (2024). HiMAL: Multimodal Hierarchical Multi-task Auxiliary Learning framework for predicting Alzheimer's disease progression. *JAMIA Open*, 7(3), ooae087. <https://doi.org/10.1093/jamiaopen/ooae087>

- Kumar, S., Yu, S., Michelson, A., Kannampallil, T., & Payne, P. (2024). HiMAL: A Multimodal Hierarchical Multi-task Auxiliary Learning framework for predicting and explaining Alzheimer disease progression. *JAMIA Open*, 7(3), ooae087.  
<https://doi.org/10.1093/jamiaopen/ooae087>
- Li, H., Habes, M., Wolk, D. A., & Fan, Y. (2019). A deep learning model for early prediction of Alzheimer's disease dementia based on hippocampal MRI (No. arXiv:1904.07282). arXiv.  
<https://doi.org/10.48550/arXiv.1904.07282>
- Revised criteria for diagnosis and staging of Alzheimer's disease: Alzheimer's Association Workgroup – Jack – 2024 – Alzheimer's & Dementia – Wiley Online Library.* (s/f). Recuperado el 20 de noviembre de 2025, de <https://alz-journals.onlinelibrary.wiley.com/doi/10.1002/alz.13859>
- Wu, X., Peng, C., Nelson, P. T., & Cheng, Q. (2022a). Machine Learning Approach Predicts Probability of Time to Stage-Specific Conversion of Alzheimer's Disease. *Journal of Alzheimer's disease : JAD*, 90(2), 891–903. <https://doi.org/10.3233/JAD-220590>
- Wu, X., Peng, C., Nelson, P. T., & Cheng, Q. (2022b). Machine Learning Approach Predicts Probability of Time to Stage-Specific Conversion of Alzheimer's Disease. *Journal of Alzheimer's Disease*, 90(2), 891–903. <https://doi.org/10.3233/JAD-220590>
- Zhang, J., Zhang, Y., Wang, J., Xia, Y., Zhang, J., & Chen, L. (2024a). Recent advances in Alzheimer's disease: Mechanisms, clinical trials and new drug development strategies. *Signal Transduction and Targeted Therapy*, 9(1), 211. <https://doi.org/10.1038/s41392-024-01911-3>
- Zhang, J., Zhang, Y., Wang, J., Xia, Y., Zhang, J., & Chen, L. (2024b). Recent advances in Alzheimer's disease: Mechanisms, clinical trials and new drug development strategies. *Signal Transduction and Targeted Therapy*, 9(1), 211. <https://doi.org/10.1038/s41392-024-01911-3>